

*Cơ sở
Thống kê
cho Khoa học dữ liệu*

Tô Đức Khánh, Nguyễn Thành Duy

Phiên bản 1.0

Ngày 1 tháng 7 năm 2026

Copyright © 2026 Tô Đức Khánh

Khoa Toán – Tin học
Trường Đại học Khoa học tự nhiên
ĐHQG-HCM

Website:

https://toduckhanh.github.io/book_stats_4_ds

Biên soạn phục vụ giảng dạy học phần *Cơ sở Thống kê cho Khoa học dữ liệu*.

Mục lục

Lời nói đầu	iii
Mục tiêu	iii
Phạm vi của cuốn sách	iii
Phần mềm và code R	iii
Giấy phép	iii
Về tác giả	v
Hướng dẫn sử dụng sách	vii
Danh sách ký hiệu	ix
1 Dữ liệu Thống kê	1
1.1 Thống kê	1
1.2 Dữ liệu thống kê	5
1.3 Kỹ thuật thu thập dữ liệu	6
2 Biến ngẫu nhiên	9
2.1 Biến ngẫu nhiên	9
2.2 Vector ngẫu nhiên	11
2.3 Sự độc lập	11
3 Trục quan hóa dữ liệu	13
3.1 Sự liên hệ giữa dữ liệu và biến ngẫu nhiên	13
3.2 Ước lượng các đặc trưng của dữ liệu	13
3.3 Trục quan dữ liệu bởi số tổng hợp	16
3.4 Trục quan dữ liệu bởi biểu đồ	16
3.5 Trục quan mối liên hệ trong dữ liệu	16
4 Footnotes and citations	17
4.1 Footnotes	17
4.2 Citations	17

5	Blocks	19
5.1	Equations	19
5.2	Theorems and proofs	19
5.3	Callout blocks	19
6	Sharing your book	21
6.1	Publishing	21
6.2	404 pages	21
6.3	Metadata for sharing	21
A	Một số chứng minh	23
A.1	Chứng minh Định lý Glivenko–Cantelli	23

Lời nói đầu

Mục tiêu

Cuốn sách này được biên soạn cho các học phần **Lý thuyết thống kê**, **Xử lý dữ liệu thống kê** tại Khoa Toán – Tin học, Trường Đại học Khoa học tự nhiên, ĐHQG-HCM.

Nội dung bao gồm:

- Thống kê mô tả
 - Xác suất
 - Suy luận thống kê
 - Hồi quy
 - Các phương pháp hiện đại trong khoa học dữ liệu
-

Phạm vi của cuốn sách

Phần mềm và code R

Giấy phép

All the material in this book is licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International Public License (CC BY-NC-ND 4.0). You may not use this material except in compliance with the aforementioned license. The human-readable summary of the license states that:

- **You are free to:**
 - *Share* – Copy and redistribute the material in any medium or format.
- **Under the following terms:**
 - *Attribution* – You must give appropriate credit, provide a link to the license, and indicate

if changes were made. You may do so in any reasonable manner, but not in any way that suggests the licensor endorses you or your use.

- *NonCommercial* – You may not use the material for commercial purposes.
- *NoDerivatives* – If you remix, transform, or build upon the material, you may not distribute the modified material.

Về tác giả

...

Hướng dẫn sử dụng sách

...

Danh sách ký hiệu


...

Chương 1

Dữ liệu Thống kê

1.1 Thống kê

Thống kê (*Statistics*) là một ngành khoa học của việc thu thập, phân tích, biểu diễn và giải thích dữ liệu, nhằm tìm ra các bằng chứng để củng cố hoặc bác bỏ các giả thuyết khoa học, với quy trình thống kê khép kín được biểu diễn trong Hình 1.1.



Hình 1.1 – Quy trình thống kê từ đặt vấn đề nghiên cứu đến kết luận.

Một số khái niệm sau cần làm rõ:

- Câu hỏi nghiên cứu là gì?
- Lập kế hoạch cho một nghiên cứu thống kê là gì?
- Ý nghĩa thống kê là gì? và tại sao ta phải sử dụng các phương pháp thống kê trong các vấn đề của sinh học?

Một câu hỏi nghiên cứu là “một câu hỏi mà một dự án nghiên cứu đặt ra để trả lời”. Trong sinh học, câu hỏi nghiên cứu có thể là:

- sự khác biệt về hình thái giữa cua cái và cua đực, hay cua xanh và cam là gì?
- tại sao mức độ hoạt động của MAO (monoamino oxidase) lại khác nhau giữa các nhóm bệnh nhân tâm thần phân liệt?
- làm thế nào để phân loại các loài hoa iris dựa trên đặc điểm của chúng?
- có sự khác biệt nào giữa 3 loài chim cánh cụt: Adelie, Chinstrap và Gentoo?
- tỷ lệ 3:1 liệu có luôn luôn đúng trong di truyền?
- biểu hiện gen (gene expression) của một số gen có khác nhau giữa người bệnh và người khỏe mạnh?
- và nhiều hơn nữa ...

Lập kế hoạch nghiên cứu là một bước rất quan trọng trong nghiên cứu phân tích dữ liệu. Ta cần làm rõ những yếu tố sau:

1. Đối tượng của nghiên cứu, có thể là, người, động vật, thực vật, tế bào, máy móc,
2. Khoanh vùng đối tượng của nghiên cứu, có thể là khu vực sinh sống; mức thu nhập, cơ quan trên cơ thể sinh vật (tim, não, cây, thân, lá), tình trạng sức khỏe.
3. Các biến (ngẫu nhiên) cần được quan sát để phục vụ cho việc phân tích và trả lời câu hỏi nghiên cứu, bao gồm 02 loại biến: biến dạng số hay định lượng (quantitative variable) và biến danh mục hay biến định tính (qualitative variable).
4. Cách thức thu thập dữ liệu (hay mẫu), thường là thông qua quan sát thực tế (observational study) hoặc thông qua các thí nghiệm (experimental study).

Ta xét một số ví dụ sau.

Ví dụ 1.1 (Monoamine oxidase (MAO) v.s. bệnh tâm thần phân liệt (schizophrenia)). Monoamine oxidase (MAO) là một loại enzyme được cho là có vai trò trong việc điều chỉnh hành vi của não bộ, đặc biệt, nồng độ MAO có thể liên quan tới các tình trạng của bệnh tâm thần phân liệt (schizophrenia), đọc thêm trong Potkin et al. (1978).

Theo thông tin tổng hợp từ bài báo khoa học, ta tổng hợp được các thông tin sau.

1. **Câu hỏi nghiên cứu:** MAO có liên quan tới tình trạng của bệnh nhân tâm thần phân liệt?
2. **Đối tượng nghiên cứu:** bệnh nhân tâm thần phân liệt với các tình trạng khác nhau.
3. **Khoanh vùng đối tượng:** bệnh nhân tâm thần phân liệt tại một khu vực sinh sống nhất

định.

4. **Biến cần quan sát:**

- nồng độ MAO của bệnh nhân tâm thần phân liệt;
- tình trạng bệnh;
- độ tuổi;
- giới tính.

5. **Cách thức lấy mẫu:** quan sát thu thập dữ liệu thực tế.

Ví dụ 1.2 (Kích thước cơ thể và mức tiêu thụ năng lượng). Chúng ta thường nghĩ rằng người to/lớn hơn thì sẽ cần nhiều năng lượng hơn. Nhưng liệu điều này có đúng? Để tìm hiểu về mối liên hệ giữa sự tiêu hao năng lượng và khối lượng không mỡ ở nam giới và phụ nữ, Webb (1981) đã thực hiện một nghiên cứu trên 15 nam giới và nữ giới trưởng thành, tuổi từ 22 tới 55. Theo thông tin tổng hợp từ bài báo khoa học, ta có thể rút ra các ý chính sau.


1. **Câu hỏi nghiên cứu:** Nhu cầu đồ ăn có liên quan tới kích thước cơ thể.
2. **Đối tượng nghiên cứu:** người trưởng thành.
3. **Khoanh vùng đối tượng:** người trưởng thành tại một khu vực sinh sống nhất định.
4. **Biến cần quan sát:**
 - trọng lượng cơ thể không có chất béo (the fat-free body mass);
 - năng lượng tiêu thụ trong quá trình vận động tĩnh tại (suy nghĩ, đọc sách, nằm nghỉ);
 - tuổi;
 - giới tính.
5. **Các thức lấy mẫu:** thí nghiệm và ghi nhận quan sát dữ liệu thực tế.

Ví dụ 1.3 (Chuẩn đoán sớm bệnh Alzheimer's). Bệnh Alzheimer là một bệnh thoái hoá thần kinh tiến triển, là nguyên nhân phổ biến nhất của chứng sa sút trí tuệ (dementia), đặc trưng bởi sự suy giảm dần về trí nhớ, khả năng tư duy, ngôn ngữ, và kỹ năng thực hành hàng ngày¹. Bệnh tiến triển qua nhiều giai đoạn, từ giai đoạn trước triệu chứng (preclinical), sang giai đoạn rối loạn nhận thức nhẹ (Mild Cognitive Impairment – MCI), rồi tới giai đoạn Alzheimer đã rõ ràng hơn về mặt lâm sàng. Hiện nay chưa có cách chữa khỏi Alzheimer, nhưng nếu phát hiện sớm, có thể can thiệp để làm chậm tiến triển, cải thiện chất lượng cuộc sống. Do đó, việc phát hiện sớm tình trạng bệnh của bệnh nhân có vai trò quan trọng trong y tế.

Do Van et al. (2023) tiến hành đánh giá khả năng dự đoán nhóm tình trạng bệnh: suy giảm nhận thức chủ quan - subjective cognitive impairment (SCI), rối loạn nhận thức nhẹ (MCI) và bệnh Alzheimer, của các hồ sơ lipidomic (lipidomic profile) trong dịch não tủy (CSF) của người. Theo thông tin tổng hợp từ bài báo khoa học, ta có thể rút ra các ý chính như sau.

1. **Câu hỏi nghiên cứu:** các giá trị của các loại chất béo (lipid) khác nhau có liên quan tới tiến trình phát triển bệnh?
2. **Đối tượng nghiên cứu:** người trưởng thành có các triệu chứng rõ ràng của ba tình trạng

¹Dementia facts figures, types of dementia



Hình 1.2 – Hình minh họa quá trình suy giảm trí nhớ ở các mức độ từ nhẹ tới nặng của bệnh Alzheimer.

bệnh.

3. **Khoanh vùng đối tượng:** 1 thành phố nhất định.

4. **Biên can quan sát:**

- tình trạng bệnh, bao gồm, SCI, MCI và AD;
- giá trị đo đặc của các lipid trong CFS, ví dụ: phospholipids (PC), phosphatidylethanolamines (PE).

5. **Cách thức lấy mẫu:** thu thập mẫu dịch tủy não của người tham gia và tiến hành phân tích trong phòng thí nghiệm.

Ví dụ 1.4 (Small round blue cell tumors (SRBCTs)). Small round blue cell tumors (SRBCTs) là một nhóm các khối u ác tính, thường gặp ở trẻ em và thanh thiếu niên, có đặc điểm mô học chung là tế bào nhỏ, hình tròn, nhân đậm màu nên khi nhuộm Hematoxylin–Eosin thường thấy như những “tế bào tròn xanh” dưới kính hiển vi. Nhóm này không phải là một loại bệnh đơn lẻ mà bao gồm nhiều khối u khác nhau, điển hình như: Neuroblastoma, Ewing family of tumours, Rhabdomyosarcoma, Burkitt lymphoma ². Việc phân loại được các loại tế bào ô thư này rất quan trọng trong y tế, giúp cho các bác sĩ có các pháp đồ điều trị phù hợp. Khan et al. (2001) đã tiến hành một nghiên cứu trong đó sử dụng giá trị biểu hiện của 2308 gene (cDNA microarrays) làm chỉ số phân loại 4 nhóm tế bào ung thư. Theo thông tin tổng hợp từ bài báo khoa học, ta có thể rút ra các ý chính như sau.

1. **Câu hỏi nghiên cứu:** giá trị biểu hiện của gene có thực sự khác biệt giữa các nhóm tế bào ung thư SRBCTs?
2. **Đối tượng nghiên cứu:** trẻ em và thanh thiếu niên bị mắc SRBCTs.
3. **Khoanh vùng đối tượng:** 1 thành phố nhất định.
4. **Biên can quan sát:**
 - nhóm tế bào ung thư cụ thể;
 - giá trị biểu hiện của các gene liên quan.


²Small blue round cell tumor

5. Cách thức lấy mẫu: thu thập mẫu sinh thiết khối u và mẫu dòng tế bào của người tham gia và tiến hành phân tích gene trong phòng thí nghiệm.

Từ các ví dụ trên, ta nhận thấy rằng các nghiên cứu sinh học dù là trong lĩnh vực nào, cũng phải xuất phát từ một câu hỏi nghiên cứu cụ thể và có các bước vạch kế hoạch thiết kế và thu hoạch mẫu cụ thể. Kết quả thu được qua quá trình phân tích thống kê sẽ là củng cố các nghi vấn trước đó hoặc bác bỏ chúng, khi này ta thường nói rằng “*kết quả có ý nghĩa thống kê*”. Vậy cụ thể từ “*ý nghĩa thống kê*” là gì? Một cách kỹ thuật, **ý nghĩa thống kê** là sự quyết định của nhà phân tích thống kê rằng các kết quả trong dữ liệu không phải là hệ quả của một sự may mắn ngẫu nhiên. **Kiểm tra giả thuyết thống kê** là phương pháp mà nhà phân tích đưa ra quyết định này.


1.2 Dữ liệu thống kê

Một dữ liệu thống kê là một bộ *mẫu ngẫu nhiên* của các *đối tượng nghiên cứu*, nó bao gồm các thông tin mô tả *đặc tính của các đối tượng nghiên cứu*. Một bộ dữ liệu có thể được thu được thông qua việc quan sát và thu mẫu thực tế (*observations*), hoặc thu mẫu các đối tượng thông qua các thí nghiệm *experiments*. Một quần thể hay tổng thể (*population*) là bộ dữ liệu lớn bao gồm tất cả đối tượng nghiên cứu có thể được bao hàm trong câu hỏi nghiên cứu, trong khi đó mẫu (*sample*) là 1 phần nhỏ quần thể được lấy ngẫu nhiên và gồm các đối tượng đã được thu thập thông tin dữ liệu phục vụ nghiên cứu (xem Hình 1.3). Một đối tượng nghiên cứu được coi là một đơn vị thống kê (*statistical unit*). Trong dữ liệu, một tính chất của đối tượng nghiên cứu thường được gán bởi một biến ngẫu nhiên (*random variable*).



Hình 1.3 – Minh họa quần thể (*population*) và mẫu ngẫu nhiên (*sample*).

Về mặt kỹ thuật, dữ liệu được phân thành hai dạng: **dữ liệu có cấu trúc** (*structured data*) và **dữ liệu phi cấu trúc** (*unstructured data*), như minh họa trong Hình 1.4. Trong đó, dữ liệu có cấu trúc được chia thành hai nhóm chính là **biến dạng số** (*numerical variable*) và **biến dạng thể**



Hình 1.4 – Sơ đồ phân chia dữ liệu: dữ liệu cấu trúc và dữ liệu phi cấu trúc.

loại (*categorical variable*). Ngược lại, dữ liệu phi cấu trúc bao gồm hình ảnh, âm thanh, văn bản và video.

Cụ thể, dữ liệu có cấu trúc bao gồm các dạng sau.

Biến dạng số (*numerical variable* hay *quantitative variable*) Là biến ngẫu nhiên có giá trị là các số, dùng để biểu diễn hoặc đo lường đại lượng của đối tượng nghiên cứu. Biến dạng số được chia thành:

- biến liên tục (*continuous variable*);
- biến rời rạc hay biến đếm (*discrete variable*).

Biến dạng thể loại (*categorical variable* hay *qualitative variable*) Là biến ngẫu nhiên có giá trị là các nhóm hoặc thể loại của đối tượng nghiên cứu. Hai dạng phổ biến là:

- biến định danh (*nominal variable*);
- biến thứ bậc (*ordinal variable*).

Riêng đối với biến định danh, có thể phân thành:

- biến nhị phân (*binary variable*), khi biến chỉ có hai giá trị;
- biến đa định danh (*multinomial nominal variable* hoặc *multinomial variable*), khi biến có từ ba giá trị trở lên.

Ví dụ 1.5 (...). *[[cung cấp ví dụ về dữ liệu có cấu trúc và các dạng biến]]*

1.3 Kỹ thuật thu thập dữ liệu


Về cơ bản ta có ba kỹ thuật lấy mẫu ngẫu nhiên cơ bản sau.

Lấy mẫu ngẫu nhiên đơn giản (*simple random sampling*) Là cách lấy mẫu ngẫu nhiên mà trong đó, ta chọn ngẫu nhiên n đối tượng từ quần thể sao cho mỗi đối tượng chỉ được chọn một lần, với xác suất được chọn là như nhau và các đối tượng được chọn là độc lập với nhau.

Lấy mẫu ngẫu nhiên theo cụm (*cluster random sampling*) Là cách lấy mẫu ngẫu nhiên mà trong đó, ta chọn ngẫu nhiên **toàn bộ** các thành viên của một hoặc nhiều cụm (nhóm) thay vì chỉ chọn từng thành viên riêng lẻ. Xem Hình 1.5.


Lấy mẫu ngẫu nhiên phân tầng (*stratified random sampling*) Là cách lấy mẫu mà trước tiên quần thể được chia thành các tầng (*strata*), trong đó các cá thể trong cùng một tầng có những đặc điểm tương đồng. Sau đó, tiến hành lấy mẫu ngẫu nhiên đơn giản trong từng tầng

và kết hợp các mẫu này để tạo thành mẫu cuối cùng. Xem Hình 1.6.



Hình 1.5 – Hình minh họa hai phương pháp lấy mẫu theo cụm.

Ví dụ 1.6 (...). *[[cung cấp ví dụ về dữ liệu và các lấy tương ứng]]*



Hình 1.6 – Hình minh họa hai phương pháp lấy mẫu theo phân tầng.

Chương 2

Biến ngẫu nhiên

Trong phần này, chúng ta sẽ ôn lại các khái niệm cơ bản của biến ngẫu nhiên, vector ngẫu nhiên, cũng như các đặc trưng quan trọng của chúng. Các kiến thức này sẽ là nền tảng cho sự kết nối giữa dữ liệu và biến ngẫu nhiên, qua đó, giúp ta thuận lợi xây dựng các công cụ thống kê cho việc biểu diễn và phân tích dữ liệu.

2.1 Biến ngẫu nhiên

2.1.1 Định nghĩa biến ngẫu nhiên

Xét một phép thử ngẫu nhiên có không gian mẫu Ω . Gọi ω là một biến cố sơ cấp (hay **kết quả** của phép thử) thuộc Ω . Khi đó, ánh xạ

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R}, \\ \omega &\mapsto X(\omega) \end{aligned}$$

được gọi là **biến ngẫu nhiên** (*random variable*).


Một hàm của một hay nhiều biến ngẫu nhiên là một ánh xạ

$$Y = g(X_1, \dots, X_p),$$

trong đó g là một hàm xác định trên giá trị của các biến ngẫu nhiên. Khi đó Y cũng một biến ngẫu nhiên, và g được gọi là **hàm của biến ngẫu nhiên** (*function of random variable*). Xem minh họa trong Hình 2.1(a) và 2.1(b).

Xét theo miền giá trị của biến ngẫu nhiên, ta phân thành hai loại cơ bản là **biến ngẫu nhiên rời rạc** (*discrete random variable*) và **biến ngẫu nhiên liên tục** (*continuous random variable*).

Biến ngẫu nhiên **rời rạc** là biến ngẫu nhiên chỉ nhận các giá trị rời rạc, chẳng hạn như các số tự



(a) biến ngẫu nhiên

(b) hàm của biến ngẫu nhiên

Hình 2.1 – Minh họa biến ngẫu nhiên và hàm của biến ngẫu nhiên.

nhiên hoặc số nguyên, với tập giá trị có thể hữu hạn hoặc vô hạn đếm được. Ví dụ: số vết xước trên một bề mặt, số bộ phận bị lỗi trong 1000 bộ phận được kiểm tra hoặc số bit truyền nhận bị lỗi.

Ngược lại, biến ngẫu nhiên **liên tục** là biến ngẫu nhiên có thể nhận mọi giá trị trong một khoảng của trục số thực $\mathbb{R}$ hoặc trên toàn bộ trục số thực. Ví dụ: chiều dài, áp suất, nhiệt độ, thời gian, điện áp và trọng lượng.

2.1.2 Phân phối xác suất

Trong lý thuyết xác suất, cũng như trong áp dụng thực tế, ta thường quan tâm tới các sự kiện liên quan tới việc quan sát được một tập giá trị A của biến ngẫu nhiên X . Khi đó, xác suất xảy ra sự kiện $X \in A$, tức là $\Pr(X \in A)$, là đại lượng quan tâm. Trong phần này, ta sẽ đi qua các khía cạnh quan trọng của $\Pr(X \in A)$ tương ứng các trường hợp rời rạc và liên tục.

Định nghĩa 2.1 (Hàm xác suất của biến ngẫu nhiên rời rạc). Xét biến ngẫu nhiên rời rạc X có các giá trị có thể là $x_1, x_2, \dots, x_k$.

Hàm trọng lượng xác suất (*probability mass function*, PMF) của X là hàm

$$p(x_i) = \Pr(X = x_i),$$

thỏa mãn các điều kiện

- $0 \leq p(x_i) \leq 1$ với mọi i ;
- $\sum_{i=1}^k p(x_i) = 1$.

Hàm phân phối tích lũy (*cumulative distribution function*, CDF) của X được định nghĩa bởi

$$F(x) = \Pr(X \leq x) = \sum_{x_i \leq x} p(x_i).$$

Hàm $F(x)$ luôn thỏa mãn

- $0 \leq F(x) \leq 1$;
- nếu $x \leq y$ thì $F(x) \leq F(y)$.

Trong một số trường hợp, hàm xác suất $p(x)$ có thể được biểu diễn bằng một công thức tường minh. Tuy nhiên, đối với nhiều biến ngẫu nhiên rời rạc, hàm xác suất chỉ được cho dưới dạng **bảng phân phối xác suất**.

Định nghĩa 2.2 (Hàm xác suất của biến ngẫu nhiên liên tục). Hàm miêu tả mật độ tập trung của một biến ngẫu nhiên liên tục X trong không gian giá trị $\mathcal{X}$, được gọi là *hàm mật độ xác suất*, ký hiệu là $f(x)$, với các tính chất sau:

- $f(x)$ là khả tích;
- $f(x) \geq 0$, với mọi giá trị của x ;
- $\int_{\mathcal{X}} f(x) dx = 1$;
- $\Pr(a \leq X \leq b) = \int_a^b f(x) dx$, tức là diện tích phía dưới đường cong xác định bởi hàm $f(x)$ trong khoảng $[a, b]$ của X .

Hàm mật độ xác suất $f(x)$ được mô tả theo công thức tường minh. Hàm phân phối tích lũy của biến ngẫu nhiên liên tục X được định nghĩa bởi:

$$F(x) = \Pr(X \leq x) = \int_{-\infty}^x f(s) ds.$$

Ta có một số tính chất của $F(x)$ như sau:

- $F(x)$ là hàm liên tục, khả vi;
- đạo hàm của $F(x)$ là $f(x)$, tức là $\frac{dF(x)}{dx} = f(x)$.

2.1.3 Các đặc trưng

2.2 Vector ngẫu nhiên

2.2.1 Hàm phân phối đồng thời

2.2.2 Các đặc trưng của vector ngẫu nhiên

2.2.3 Hàm phân phối lề

2.2.4 Hàm phân phối điều kiện

2.3 Sự độc lập

Chương 3

Trực quan hóa dữ liệu

3.1 Sự liên hệ giữa dữ liệu và biến ngẫu nhiên

3.1.1 Dữ liệu và biến ngẫu nhiên

Ghi nhớ 3.1. *Ta thống nhất các ký hiệu sau:*

- *Mẫu ngẫu nhiên (random sample):* $X_1, \dots, X_n$ là các biến ngẫu nhiên độc lập và cùng phân phối (independent and identically distributed - iid).
- *Dữ liệu quan sát (observed data):* $x_1, \dots, x_n$ là các giá trị thu được từ mẫu ngẫu nhiên.
- *Bộ dữ liệu (dataset):* tập hợp dữ liệu được lưu trữ để phân tích, có thể gồm nhiều biến, nhiều bảng hoặc nhiều kiểu dữ liệu khác nhau.

3.1.2 Sự chuyển đổi biến

3.2 Ước lượng các đặc trưng của dữ liệu

Trong phần này, ta nghiên cứu các ước lượng của các đặc trưng của một biến ngẫu nhiên X dựa trên một mẫu ngẫu nhiên, $X_1, \dots, X_n$, gồm n biến ngẫu nhiên độc lập và cùng phân phối theo hàm phân phối $F_X(x)$. Ta thường viết tắt bởi $X_i \stackrel{\text{iid}}{\sim} F_X(x)$, với $i = 1, \dots, n$.

3.2.1 Phân phối thực nghiệm

Nhắc lại rằng mẫu ngẫu nhiên là một tập hợp các đơn vị thống kê được chọn từ quần thể và kỳ vọng có tính đại diện cho quần thể đó. Do đó, mặc dù phân phối lý thuyết của quần thể hay của biến ngẫu nhiên X thường chưa biết, ta có thể sử dụng các giá trị quan sát của mẫu để xây dựng phân phối thực nghiệm (**empirical distribution**), từ đó suy luận về phân phối của quần thể.

Định nghĩa 3.2 (Phân phối thực nghiệm). Xét một mẫu ngẫu nhiên $X_1, \dots, X_n$, độc lập và cùng phân phối của biến ngẫu nhiên X có hàm phân phối tích lũy $F_X(x) = \Pr(X \leq x)$. Hàm phân phối

tích lũy thực nghiệm (**empirical cumulative distribution** - ECDF) của X được xác định bởi

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(X_i \leq x), \quad (3.1)$$

là một ước lượng của F_X , với $\mathbf{I}(\cdot)$ là hàm chỉ (indicator function) và được định nghĩa như sau:

$$\mathbf{I}(u \leq a) = \begin{cases} 1 & \text{nếu } u \leq a, \\ 0 & \text{nếu } u > a. \end{cases}$$

Hàm phân phối tích lũy thực nghiệm trong phương trình (3.1) là một trong những công cụ cơ bản và lâu đời nhất của thống kê phi tham số. Ý tưởng xây dựng ECDF xuất phát từ việc thay thế phân phối lý thuyết chưa biết của quần thể bằng tần suất tích lũy quan sát được từ mẫu. Mặc dù khái niệm này đã xuất hiện từ rất sớm trong thống kê toán học, nền tảng lý thuyết của ECDF được thiết lập rõ ràng thông qua định lý Glivenko–Cantelli, chứng minh rằng hàm phân phối thực nghiệm hội tụ đều đến hàm phân phối thực của quần thể khi cỡ mẫu lớn (Glivenko, 1933; Cantelli, 1933). Kể từ đó, ECDF trở thành nền tảng của nhiều phương pháp thống kê phi tham số, bao gồm kiểm định Kolmogorov–Smirnov, kiểm định Cramér–von Mises, ước lượng phân vị và các kỹ thuật bootstrap hiện đại (van der Vaart, 1998; Wasserman, 2004).

Định lý 3.3 (Định lý Glivenko–Cantelli). *Xét một mẫu ngẫu nhiên $X_1, \dots, X_n$, độc lập và cùng phân phối của biến ngẫu nhiên X có hàm phân phối tích lũy $F_X(x)$. Ký hiệu $\hat{F}_n(x)$ là hàm phân phối tích lũy thực nghiệm được xây dựng từ mẫu ngẫu nhiên. Khi đó,*

$$\sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F_X(x) \right| \xrightarrow{\text{a.s.}} 0,$$

khi $n \rightarrow +\infty$.

[[Bổ sung chứng minh trong phụ lục.]]

Từ định lý Glivenko–Cantelli ta có kết quả quan trọng sau cho việc ước lượng phân phối tích lũy tại một giá trị cố định.

Hệ quả 3.4. *Với mọi $x \in \mathbb{R}$,*

$$\hat{F}_n(x) \xrightarrow{\text{a.s.}} F_X(x),$$

khi $n \rightarrow +\infty$. Do đó, ta nói $\hat{F}_n(x)$ là một ước lượng vững của $F_X(x)$.

3.2.2 Ước lượng mật độ xác suất

Hàm mật độ xác suất của biến ngẫu nhiên ngoài công dụng trong việc xác định xác suất tích lũy, thì nó cũng biểu diễn sự phân bố của giá trị lý thuyết của biến ngẫu nhiên, trong đó, vùng có giá trị mật độ xác suất cao nhất thì tương ứng với vùng có khả năng cao có thể quan sát được giá trị của

biến ngẫu nhiên.

Trong phần trước, ta đã được giới thiệu tới hàm phân phối tích lũy thực nghiệm $\hat{F}_n(x)$, từ hàm này, ta hoàn toàn có thể xác định được hàm mật độ xác suất cho mẫu ngẫu nhiên. Nhắc lại rằng, hàm mật độ xác suất lý thuyết của một biến ngẫu nhiên liên tục X , được ký hiệu là $f_X(x)$ và được xác định bởi

$$f_X(x) = \frac{d}{dx} F_X(x)$$

, tức là đạo hàm của hàm phân phối tích lũy lý thuyết $F_X(x)$.

Xét một mẫu ngẫu nhiên $X_1, \dots, X_n$, độc lập và cùng phân phối của biến ngẫu nhiên X có hàm phân phối tích lũy $F_X(x)$ và hàm mật độ xác suất $f_X(x)$ (chưa biết). Hàm xác suất tích lũy thực nghiệm $\hat{F}_n(x)$ trong (3.1) là ước lượng của $F_X(x)$. Ta mong muốn ước lượng được hàm mật độ xác suất $f_X(x)$ dựa trên mẫu ngẫu nhiên. Áp dụng định nghĩa của hàm mật độ xác suất, ta có thể viết

$$\hat{f}_n(x) = \frac{d}{dx} \hat{F}_n(x).$$

Tuy nhiên $\hat{F}_n(x)$ là không liên tục, do đó ta cần áp dụng xấp xỉ sai phân trung tâm (central difference approximation) với bước nhảy $h > 0$, khi này, ta có

$$\begin{aligned} \hat{f}_n(x) &= \frac{\hat{F}_n(x + h/2) - \hat{F}_n(x - h/2)}{h} \\ &= \frac{1}{nh} \sum_{i=1}^n \mathbf{I} \left(\frac{|Y_i - x|}{h} \leq \frac{1}{2} \right). \end{aligned} \quad (3.2)$$

Ước lượng này được gọi là ước lượng mật độ tần số thực nghiệm (the histogram estimator) được đề xuất và nghiên cứu các tính chất thống kê bởi Freedman and Diaconis (1981). Tham số h được gọi là “độ rộng” (bandwidth). Ta dễ dàng kiểm chứng được các tính chất cho $\hat{f}_n(x)$ (xem thêm trong phụ lục ...).

Không giống như hàm phân phối tích lũy thực nghiệm, hàm mật độ tần số thực nghiệm bị ảnh hưởng bởi việc lựa chọn độ rộng h . Khi h càng nhỏ ($h \rightarrow 0$) thì hàm mật độ tần số thực nghiệm sẽ càng gấp khúc, trong khi giá trị lớn của h tạo ra ước lượng mật độ có vẻ trơn, tuy nhiên, nếu h quá lớn thì tính chính xác của ước lượng không còn được đảm bảo. Freedman and Diaconis (1981) đề xuất một cách chọn h “tối ưu” là $h_{\text{opt,FD}} = 2\text{IQR}n^{-1/3}$.

3.2.3 Trung bình mẫu và phương sai mẫu

3.2.4 Phân vị mẫu

3.3 Trực quan dữ liệu bởi số tổng hợp

3.4 Trực quan dữ liệu bởi biểu đồ

3.4.1 Biểu đồ stem-leaf

3.4.2 Biểu đồ điểm

3.4.3 Biểu đồ histogram

3.4.4 Biểu đồ boxplot

3.4.5 Biểu đồ mật độ xác suất

3.5 Trực quan mối liên hệ trong dữ liệu

3.5.1 Biểu đồ side-by-side boxplot

3.5.2 Hệ số tương quan

Chương 4

Footnotes and citations

4.1 Footnotes

Footnotes are put inside the square brackets after a caret `^[]`. Like this one ¹.

4.2 Citations

Reference items in your bibliography file(s) using `@key`.

For example, we are using the **bookdown** package (Xie, 2026) (check out the last code chunk in `index.Rmd` to see how this citation key was added) in this sample book, which was built on top of R Markdown and **knitr** (Xie, 2015) (this citation was added manually in an external file `book.bib`). Note that the `.bib` files need to be listed in the `index.Rmd` with the YAML **bibliography** key.

The RStudio Visual Markdown Editor can also make it easier to insert citations: <https://rstudio.github.io/visual-markdown-editing/#/citations>

¹This is a footnote.

Chương 5

Blocks

5.1 Equations

Here is an equation.

$$f(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (5.1)$$

You may refer to using `\@ref{eq:binom}`, like see Equation (5.1).

5.2 Theorems and proofs

Labeled theorems can be referenced in text using `\@ref{thm:tri}`, for example, check out this smart theorem 5.1.

Định lý 5.1. *For a right triangle, if c denotes the length of the hypotenuse and a and b denote the lengths of the **other** two sides, we have*

$$a^2 + b^2 = c^2$$

Read more here <https://pkg.yihui.org/bookdown/markdown-extensions-by-bookdown.html>.

5.3 Callout blocks

The R Markdown Cookbook provides more help on how to use custom blocks to design your own callouts: <https://yihui.org/rmarkdown-cookbook/custom-blocks.html>

Chương 6

Sharing your book

6.1 Publishing

HTML books can be published online, see: <https://pkg.yihui.org/bookdown/publishing.html>

6.2 404 pages

By default, users will be directed to a 404 page if they try to access a webpage that cannot be found. If you'd like to customize your 404 page instead of using the default, you may add either a `_404.Rmd` or `_404.md` file to your project root and use code and/or Markdown syntax.

6.3 Metadata for sharing

Bookdown HTML books will provide HTML metadata for social sharing on platforms like Twitter, Facebook, and LinkedIn, using information you provide in the `index.Rmd` YAML. To setup, set the `url` for your book and the path to your `cover-image` file. Your book's `title` and `description` are also used.

This `gitbook` uses the same social sharing data across all chapters in your book- all links shared will look the same.

Specify your book's source repository on GitHub using the `edit` key under the configuration options in the `_output.yml` file, which allows users to suggest an edit by linking to a chapter's source file.

Read more about the features of this output format here:

<https://pkgs.rstudio.com/bookdown/reference/gitbook.html>

Or use:

```
?bookdown::gitbook
```

Phụ lục A

Một số chứng minh

A.1 Chứng minh Định lý Glivenko–Cantelli

Định lý Glivenko–Cantelli là một trong những kết quả nền tảng của thống kê phi tham số. Một cách chứng minh hiện đại dựa trên bất đẳng thức Dvoretzky–Kiefer–Wolfowitz (DKW).

Gợi ý chứng minh. Xét hàm phân phối tích lũy thực nghiệm

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(X_i \leq x).$$

Ta cần chứng minh rằng

$$\sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F_X(x) \right| \xrightarrow{\text{a.s.}} 0.$$

Ý tưởng chứng minh gồm các bước sau.

1. Với mỗi x cố định, biến ngẫu nhiên $\mathbf{I}(X_i \leq x)$ có phân phối Bernoulli với kỳ vọng $\mathbb{E} [\mathbf{I}(X_i \leq x)] = F_X(x)$.
2. Theo Luật số lớn dạng mạnh (Strong Law of Large Number),

$$\hat{F}_n(x) \xrightarrow{\text{a.s.}} F_X(x),$$

với mọi x cố định.

3. Kết quả trên mới chỉ cho sự hội tụ tại từng điểm. Để nâng lên thành hội tụ đều trên toàn bộ trục số, ta sử dụng bất đẳng thức Dvoretzky–Kiefer–Wolfowitz:

$$\Pr \left(\sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F(x) \right| > \varepsilon \right) \leq 2 \exp(-2n\varepsilon^2),$$

với mọi $\varepsilon > 0$.

4. Vì

$$\sum_{n=1}^{\infty} 2 \exp(-2n\varepsilon^2) < +\infty,$$

nên theo bổ đề Borel–Cantelli,

$$\sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F_X(x) \right| \xrightarrow{\text{a.s.}} 0.$$

Điều này hoàn tất chứng minh định lý.

□

Tài liệu tham khảo

- Cantelli, F. P. (1933). Sulla determinazione empirica delle leggi di probabilità. *Giornale dell'Istituto Italiano degli Attuari*, 4:421–424.
- Do Van, K., To Duc, K., and Pham Luong, T. (2023). Lipidomic analysis reveals biomarkers for alzheimer’s disease. In *2023 1st International Conference on Health Science and Technology (ICHST)*, pages 1–8. IEEE.
- Freedman, D. and Diaconis, P. (1981). On the histogram as a density estimator: L_2 theory. *Zeitschrift für Wahrscheinlichkeitstheorie und verwandte Gebiete*, 57(4):453–476.
- Glivenko, V. (1933). Sulla determinazione empirica delle leggi di probabilità. *Giornale dell'Istituto Italiano degli Attuari*, 4:92–99.
- Khan, J., Wei, J. S., Ringner, M., Saal, L. H., Ladanyi, M., Westermann, F., Berthold, F., Schwab, M., Antonescu, C. R., Peterson, C., et al. (2001). Classification and diagnostic prediction of cancers using gene expression profiling and artificial neural networks. *Nature Medicine*, 7(6):673–679.
- Potkin, S. G., Cannon, H. E., Murphy, D. L., and Wyatt, R. J. (1978). Are paranoid schizophrenics biologically different from other schizophrenics? *New England Journal of Medicine*, 298(2):61–66.
- van der Vaart, A. W. (1998). *Asymptotic Statistics*. Cambridge University Press.
- Wasserman, L. (2004). *All of Statistics*. Springer.
- Webb, P. (1981). Energy expenditure and fat-free mass in men and women. *The American Journal of Clinical Nutrition*, 34(9):1816–1826.
- Xie, Y. (2015). *Dynamic Documents with R and knitr*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition. ISBN 978-1498716963.
- Xie, Y. (2026). *bookdown: Authoring Books and Technical Documents with R Markdown*. R package version 0.47.